

Titanic 데이터셋 생존 예측 실무 분석 보고서

이인수

이메일: ii3289857@gmail.com

Abstract—본 보고서는 Kaggle Titanic 데이터셋 기반의 이진 생존 분류 문제를 데이터 누수(Data Leakage) 방지 프로토콜에 따라 체계적으로 분석한다. 모든 모델링 의사결정에 앞서 층화 80/20 홀드아웃 분할을 고정하였으며, 모델에 투입되는 모든 결측치 대체값, 범주형 인코딩, 스케일링 통계량은 교차검증 파이프라인 내부에서만 학습되도록 구축하였다. 도메인 지식 기반 특성 공학(호칭 추출, 가족 규모 구간화, 1인당 로그 요금, 결측치 시 플래그)을 적용한 로지스틱 회귀 베이스라인은 교차검증 정확도 0.829 ± 0.028 를 기록하여 고전적 성별 지수 규칙(0.789) 대비 우수한 성능을 입증하였다. 아울러 짝지은 소거 분석(Ablation Analysis), 네 가지 트리 앙상블 모델, 무작위 하이퍼파라미터 탐색, 그리고 4단계 성능 천장 분석(학습 곡선, 오류 교집합 분석, 복합 앙상블링, 승객 프로파일 불일치 상한 측정)을 수행한 결과, 추가적인 특성 공학 및 모델 구조 변경이 베이스라인 대비 유의미한 성능 향상을 도출하지 못함을 검증하였다. 잔여 오류의 약 50%는 모든 모델 계열이 공통적으로 오분류하는 특성을 보였으며, 이산 승객 프로파일을 암기하더라도 표본 내(In-sample) 정확도는 0.851 수준에 제한되었다. 미사용 독립 테스트 데이터셋에 대한 최종 1회 평가 결과, 정확도 0.838, F1 점수 0.788, ROC-AUC 0.865를 달성하여 교차검증 추정치와 일치함을 확인하였다. 본 분석 결과는 관측된 승객 메타데이터만으로는 예측 정확도가 0.83–0.84 구간에서 포화하며, 잔여 오류는 관측되지 않은 환경적 요인에 의해 지배됨을 시사한다.

Index Terms—타이타닉 생존 예측, 데이터 누수 방지, 교차검증 파이프라인, 소거 분석, 성능 천장 분석, 이진 분류

I. 서론

Titanic 데이터셋은 승객 891명의 인구통계 및 승선 메타데이터로부터 생존 여부를 예측하는 대표적인 이진 분류 벤치마크이다. 본 문제는 변수의 수가 적고 구조가 단순하지만, 탐색적 데이터 분석, 결측치 대체 통계량 산출, 특성 선택 및 모델 최적화 과정에서 평가 데이터셋의 정보가 사전 유입되는 데이터 누수(Data Leakage)로 인해 모델의 성능이 과대평가되기 쉽다. 본 보고서의 주요 목적은 다음과 같다:

- 1) 모든 결측치 대체값, 인코딩, 스케일링 통계량이 교차검증 내부에서 엄격하게 학습되는, 데이터 누수가 차단된 분류 파이프라인을 구축한다.
- 2) 도출된 예측 성능의 한계를 다각도로 검증하고, 성능 개선의 정체가 모델링 미숙이 아닌 주어진 특성 데이터 집합의 정보적 한계(성능 천장, Performance Ceiling)에 기인함을 실증적으로 제시한다.

II. 데이터셋 및 평가 프로토콜

본 보고서에서는 Kaggle의 표준 Titanic 훈련 데이터셋(891개 관측치, 12개 속성, 생존율 38.4%)을 활용한다. 데이터 누수를 방지하기 위해, 모든 특성 공학 및 모델링 의사결정에 앞서 전체 데이터를 종속 변수 기준 층화 무작위 추출(Stratified Random Sampling)을 통해 개발 데이터셋(Development Set, 712개 관측치)과 최종 검증용 테스트 데이터셋(Test Set, 179개 관측치)으로 80:20 분할하였다(random_state=42).

평가 프로토콜은 다음과 같이 엄격히 고정하였다:

- 모든 탐색적 데이터 분석, 특성 공학 및 선택, 모델 탐색 및 하이퍼파라미터 최적화는 개발 데이터셋 내에서만 수행하며, 층화 5-겹 교차검증(Stratified 5-Fold Cross-Validation, 짝지은 비교 시 동일한 겹 구성을 공유하는 5-Fold $\times$ 3회 반복 교차검증)을 통해 성능을 평가한다.
- 테스트 데이터셋은 최후의 단일 최종 모델에 대해서만 단 1회 평가에 사용한다(제VI절).

초기 기술 통계 분석(제III절)은 데이터 분할 이전의 전체 데이터셋(891개 관측치)을 대상으로 탐색적으로 수행되었다. 이는 개략적인 탐색 방향 설정 목적으로만 활용되었으며, 모델 학습에 투입되는 모든 통계량은 개발 데이터셋 상에서 독자적으로 재산출되었다.

III. 탐색적 데이터 분석

A. 변수 분포

나이(Age) 변수는 20–30세를 중심축으로 하는 단봉 분포 형태에 영유아 구간의 소규모 봉우리가 결합된 양상을 나타내며, 요금(Fare) 변수는 극단적인 우측 왜도(Right-skewed Distribution, 중앙값 14.5, 최댓값 512.3)를 형성한다. 승객의 68–76%는 동반 가족(형제·배우자 또는 부모·자녀) 없이 단독으로 탑승하였다(그림 1). 성별(Sex)은 가장 강력한 단일 예측 변수로 작용하며(여성 생존율 74% 대 남성 생존율 19%), 객실 등급(Pclass)이 그 뒤를 잇는다(1등석 63%, 2등석 47%, 3등석 24%).




Fig. 1. 특성 변수 분포 (데이터 분할 이전 전체 데이터셋 기준 — 탐색적 방향 설정 용도로 활용).

B. 결측치 메커니즘

Age 변수는 19.9%, Cabin 변수는 77.1%, Embarked 변수는 2개의 관측치에서 결측이 관측되었다. 개발 데이터셋 분석 결과, Age의 결측 여부 자체가 종속 변수에 대한 유의미한 정보성(Informative Missingness)을 내포함을 확인하였다(결측 그룹 생존율 29% 대 관측 그룹 41%; 결측은 주로 3등석 승객에 집중됨). 이는 비임의 결측(Missing Not At

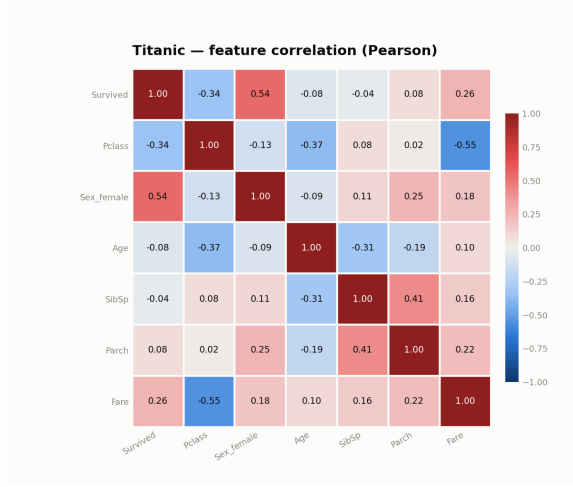


Fig. 2. Pearson 상관관계 행렬, Pclass와 Fare 간에는 강한 음의 상관관계(-0.55)가 존재하며, 종속 변수와의 상관관계는 Sex 변수가 주도한다(+0.54).

Random, MNAR) 메커니즘에 해당한다. 승객 이름(Name)에서 추출한 호칭(Title) 범주별 중앙 나이 차이가 명확하므로(Master 3세, Miss 22세, Mr 30세, Mrs 35세, 기타/Rare 49세), 호칭 조건부 결측치 대체 방식과 명시적 결측치 지시 플래그(Missing Indicator) 생성을 병행하였다. 객실 정보의 기재 여부(CabinKnown) 또한 1등석 내부 승객의 생존율 차이를 설명하므로(기재 그룹 70% 대 미기재 그룹 46%), 독자적인 예측 특성으로 반영하였다(그림 3).




Fig. 3. 개발 데이터셋의 결측 메커니즘 분석.

C. 이상치 분석

사분위 범위(Interquartile Range, IQR) 기준 이상치 탐지 결과, 70~80세 고령 승객 관측치, 극단적인 요금 분포의 롱테일(Long-tail) 관측치(동일 티켓을 공유하는 그룹 관측치로 설명되며 최댓값은 512.3임), 그리고 요금이 0으로 기재된 14개의 승객 관측치가 확인되었다(그림 4). 해당 관측치들이 데이터 입력 오류가 아닌 실제 도메인 현상을 반영하는 것으로 판단됨에 따라 제거하지 않았으며, 요금 변수의 왜도는 1인당 로그 요금 변환을 통해 완화하였다.



Fig. 4. 개발 데이터셋의 이상치 탐지 결과.

IV. 전처리 및 특성 공학

본 보고서의 전처리 및 모델 학습 과정은 scikit-learn의 Pipeline 객체를 통해 단일화된 구조로 구현되었다: *FeatureEngineer* → *TitleGroupAgeImputer* → *ColumnTransformer*. 모델 학습에 사용되는 모든 통계적 파라미터는 훈련 집(Training Fold) 내부에서만 분리되어 계산된다. 생성된 특성들과 도메인 선택 근거는 표 I 및 그림 5에 제시되어 있다.




TABLE I
특성 산출 및 선택 결정 (개발 데이터셋, $n = 712$). r 은 종속 변수와의 점이연 상관계수를 나타냄.

특성명	생성 방식	도메인 근거	결정
Title	Name 추출 (Mr/Mrs/Miss/Master/Rare)	호칭별 생존율 편차 (15%–79%)	채택
AgeMissing	결측 지시 변수	MNAR 메커니즘 신호 포착	채택
CabinKnown	결측 지시 변수	1등석 내부 생존율 편차 설명	채택
FamilySize	SibSp+Parch+1 (1인/2–4인/5인+)	비단조 U자형 생존율 패턴	채택
TicketGroupSize	공유 티켓 인원수 (배치 내 빈도)	동일 U자형 생존율 패턴	채택
LogFarePerPerson	$\log(1 + \text{요금}/\text{인원})$	요금도 완화 ($4.97 \rightarrow 0.35$); $r = +0.36$	Fare 대체
PassengerId	식별자	낮은 상관성 ($r = +0.01$)	제거
Name, Ticket, Cabin	원본 텍스트	고카디널리티; 파생 변수로 대체	추출 후 제거
SibSp, Parch	원본 수치 변수	FamilySize로 통합	제거

TABLE II
베이스라인 모델 성능 비교 (단일 5-FOLD CV).

모델 분류	정확도	F1 점수	ROC-AUC
다수 클래스 베이스라인	0.617	0.000	0.500
성별 지수 규칙 (여성 $\Rightarrow$ 생존)	0.789	0.715	0.770
로지스틱 회귀 (베이스라인)	0.824 ± 0.032	0.771 ± 0.030	0.877 ± 0.020

+0.93)은 부호와 상대적 크기 측면에서 탐색적 데이터 분석의 결과와 완전히 부합한다.

B. 특성 소거 분석

보류 대상 후보 변수들에 대해 개별적 추가 및 제거 소거 분석(Ablation Analysis)을 수행하였다. 실험 결과, 어떠한 특성 조합 변형도 표준편차 노이즈 범위를 초과하는 성능 향상을 제시하지 못하였다: 객실 데크 문자 추가 ($\Delta - 0.003 \pm 0.013$), 무임 승객 지시 플래그 추가 ($\Delta - 0.001 \pm 0.003$), SibSp/Parch 원본 변수 복원 ($\Delta - 0.004 \pm 0.004$), TicketGroupSize 제거 ($\Delta - 0.003 \pm 0.005$), 연속형 FamilySize 제거 ($\Delta - 0.001 \pm 0.002$) (모두 짝지은 Δ 정확도 기준). 이에 따라 최종 21개 차원의 특성 구성을 확정하였다.

C. 트리 앙상블 모델 비교

랜덤 포레스트(Random Forest), 엑스트라 트리(Extra-Trees), 그래디언트 부스팅(Gradient Boosting), 히스토그램 그래디언트 부스팅(HistGradientBoosting) 모델을 평가한 결과, 모든 트리 앙상블 계열이 선형 베이스라인과 통계적으로 동등한 수준의 성능을 형성함을 확인하였다(표 III, 그림 6). 옵션 특성 집합을 추가 적용하더라도 트리 모델 계열에서 유의미한 이득이 관측되지 않았다(짝지은 최대 성능 이득 +0.004). 검증 세트 기준 순열 특성 중요도(Permutation Importance) 분석 결과 또한 선형 모델의 해석과 일치하였다: Title 및 Sex가 가장 높은 중요도를 나타냈으며, 가족 규모 구간, 객실 등급, 객실 정보 기재 여부가 그 뒤를이었다.

D. 하이퍼파라미터 최적화

로지스틱 회귀에 대한 전수 그리드 탐색(Grid Search)과 랜덤 포레스트 및 그래디언트 부스팅 모델에 대한 60개 조합의 무작위 탐색(Randomized Search, 내부 5-Fold CV 기반)을 수행하였다. 그러나 공유된 외부 교차검증 겹에서 기본 하이퍼파라미터 설정을 능가하는 조합은 발견되지 않았다(짝지은 Δ 정확도 각각 -0.010 , -0.001 , -0.000 ; 그림 7). 내부

TABLE III
동일 반복 교차검증 겹에서의 모델 계열별 성능 비교.

알고리즘 계열	교차검증 정확도	ROC-AUC
로지스틱 회귀 (선형 베이스라인)	0.829 ± 0.028	0.877
랜덤 포레스트 (트리 500개, leaf ≥ 2)	0.831 ± 0.023	0.878
엑스트라 트리 (트리 500개, leaf ≥ 2)	0.832 ± 0.024	0.870
그래디언트 부스팅	0.829 ± 0.026	0.879
히스토그램 그래디언트 부스팅	0.806 ± 0.024	0.872

CV 상의 최고 성능 점수(≈ 0.834)와 반복 CV 재평가 점수(≈ 0.830) 간의 격차는 탐색 과정에서의 선택 편향(Selection Bias) 발생을 보여주며, 최종 모델 성능 평가가 반드시 독립된 테스트 데이터셋에 기반해야 함을 증명한다.

E. 성능 천장 분석

모델 예측 성능의 추가 개선 가능성을 검증하기 위해 4가지 독립적 실험을 실시하였다(그림 8).

- 1) 학습 곡선 분석 (Learning Curve):** 검증 정확도는 학습 데이터 수가 약 390개를 넘어서는 시점부터 평탄화 경향을 보이며(최종 구간 증분 +0.003), 학습-검증 정확도 격차 또한 ≈ 0.008 에 불과하다. 이는 데이터 샘플 수 부족이나 모델의 표현 용량(Capacity) 부족이 성능의 병목 요인이 아니음을 나타낸다.
- 2) 오류 교집합 분석 (Error Overlap Analysis):** 로지스틱 회귀, 랜덤 포레스트, 그래디언트 부스팅 중 어느 하나라도 Out-of-fold 검증에서 오분류한 172명의 승객 관측치 중 86명(50.0%)은 세 모델 계열 모두가 공통적으로 오분류하였다. 이는 잔여 오류가 특정 알고리즘의 한계가 아닌, 데이터 자체가 보유한 공통 고유 특성에 기인함을 시사한다.
- 3) 복합 앙상블 기법 검증 (Complex Ensemble Techniques):** 소프트 보팅(Soft Voting, $\Delta - 0.004$), 스택킹(Stacking, $\Delta - 0.002$), 선형 모델 내 쌍별 상호작용항(Pairwise Interaction Terms, $\Delta - 0.010$) 추가 등 복합 모델링을 적용하였으나, 짝지은 비교에서 베이스라인을 넘어서지 못하였다.
- 4) 승객 프로파일 불일치 상한 분석 (Profile Conflict Upper Bound):** 동일한 이산 프로파일(Sex, Pclass, Title, FamilyBucket, CabinKnown, Embarked)을 공유하는 승객 그룹이 전체 관측치의 81%에서 서로 상반된 생존 라벨을 보유함을 확인하였다. 해당 프로파일을

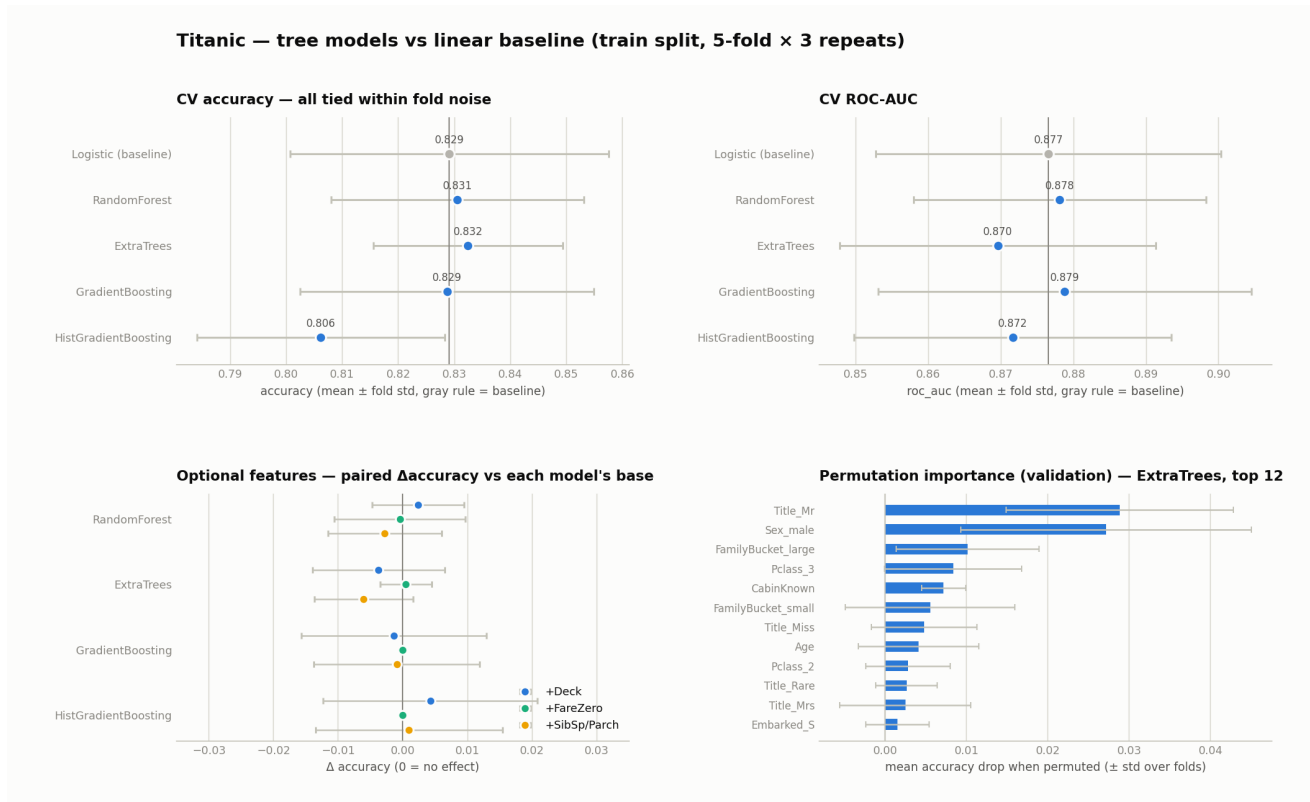


Fig. 6. 트리 앙상블 모델과 선형 베이스라인의 성능 비교, 옵션 특성 재검토 결과, 및 순열 특성 중요도 분석.




Fig. 7. 하이퍼파라미터 탐색 결과: 최적화된 하이퍼파라미터 조합이 기본 설정 대비 이득을 제공하지 못함을 보여줌.

완벽히 암기하더라도 표본 내(In-sample) 예측 정확도 상한은 0.851로 제한된다(단일 관측치 프로파일 3%를 포함한 낙관적 추정치). 일반화 손실을 고려할 때, 현재 베이스라인 모델의 교차검증 정확도(0.829)는 이론적 한계 상한에 실질적으로 도달한 상태로 평가된다.

VI. 최종 평가

동등한 성능을 보인 모델 군 중 가장 구조가 단순한, 21개 특성 파이프라인 기반 기본 설정 로지스틱 회귀를 최종 모델로 확정하였다. 이를 개발 데이터셋 전체(712개 관측치)로

재학습한 후, 미사용 상태로 보존된 홀드아웃 테스트 데이터셋(179개 관측치)에 대하여 단 1회 최종 평가를 수행하였다(표 IV, 그림 9).

VII. 결론

본 보고서에서는 Titanic 생존 예측 데이터셋에 대하여 데이터 누수가 엄격히 차단된 분류 파이프라인을 구축하여 최종 테스트 정확도 0.838을 달성하였다. 특성 소거 분석, 앙상블 모델 비교, 하이퍼파라미터 최적화, 복합 앙상블링, 상호작용 항 도입, 학습 곡선 분석, 오류 교집합 분석, 승객 프로파일

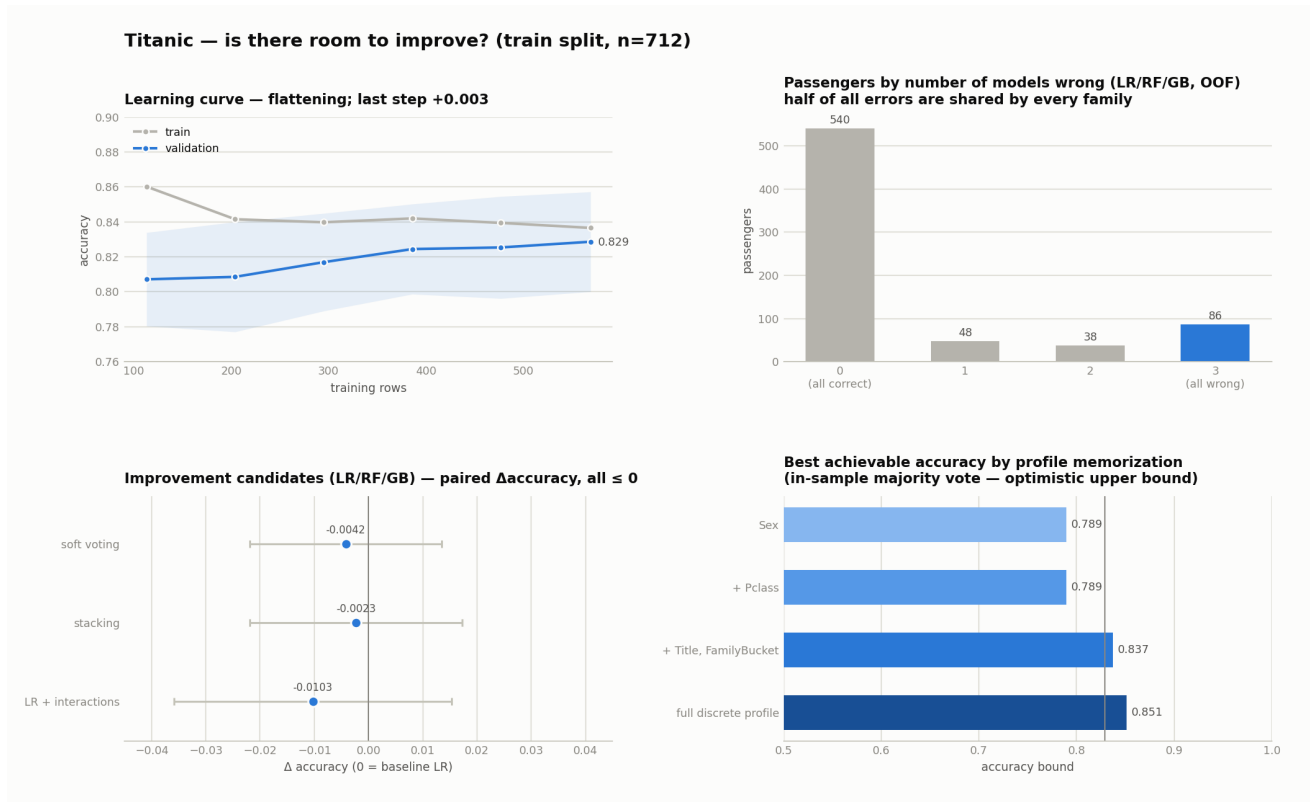


Fig. 8. 베이스라인 모델이 해당 특성 집합의 성능 천장에 도달하였음을 입증하는 4단계 실험적 근거.

TABLE IV
최종 테스트 세트 성능과 교차검증 추정치 비교.

평가 지표	최종 테스트 세트 ($n = 179$)	교차검증 추정치
정확도 (Accuracy)	0.838	0.829 ± 0.028
F1 점수 (F1-Score)	0.788	0.771 ± 0.030
ROC-AUC	0.865	0.877 ± 0.024

환경적 요인(예: 구체적 선실 위치, 구명정 접근성 등)이 지배적인 영향을 미친다고 결론지었다.




Fig. 9. 독립 테스트 데이터셋에서의 혼동 행렬(Confusion Matrix) 및 ROC 곡선.

불일치 분석으로 구성된 다각도 실험을 통해, 현재 도출된 성능이 모델링 미숙이 아닌 주어진 특성 집합이 가진 정보적 천장(Performance Ceiling)임을 입증하였다. 잔여 오류의 절반은 주요 모델 계열 전체에서 공통적으로 발생하며, 동일한 프로파일 내에서도 생존 결과의 상충이 빈번하게 관측된다. 성별, 등급, 호칭, 가족 구조, 요금, 객실 기재 여부 등 관측된 메타데이터 수준을 넘어서는 생존 예측에는 관측되지 않은